Trabalho Prático I

Integração e Análise de Marcações e Pagamentos de um Estúdio de Estética

Integração de Sistemas de Informação
Licenciatura em Engenharia de Sistemas Informáticos
Ano letivo 2026/2027

Autora: Thifany Antoni
Número de aluno: 16077
Docente: Óscar Ribeiro
Data: 22 de outubro de 2026

Resumo

Neste trabalho prático desenvolvi um processo ETL no KNIME para integrar marcações, pagamentos, serviços e clientes de um estúdio de estética fictício. O processo combina ficheiros CSV, JSON e XML com uma base de dados relacional SQLite, aplica regras de qualidade e gera três ficheiros CSV para consulta e revisão.

Temos125 linhas iniciais de marcações, e dessas foram removidas 5 cópias exatas e separadas 5 marcações sem valor. As restantes 115 originam uma tabela integrada, com valores das marcações, foi feita a separações de valores pagos, em falta, e valor total dos serviços, e foi gerada uma lista de valores mensais.

1 Enquadramento

Para este projeto, utilizei o KNIME Analytics Platform 5.12.0 na de procura demonstrar as etapas de extração, transformação e carregamento de dados previstas no enunciado.

2 Problema

Num estúdio de estética, a agenda, os pagamentos, o catálogo de serviços e os contactos podem estar guardados em sistemas diferentes. Consultar apenas a agenda não permite saber quanto foi recebido por cada marcação. Além disso, duplicados, preços em falta e emails com formatos inconsistentes dificultam a análise.

A minha solução reúne essas fontes numa tabela por marcação e calcula os valores recebidos e em falta. Mantém uma saída separada para os registos sem preço, permitindo a sua revisão sem alterar os totais.

Dados de entrada

Ficheiro	Formato e conteúdo	Quantidade
marcacoes.csv	Marcações e valor do serviço	125 linhas
pagamentos.json	Pagamentos associados às marcações	118 registos
servicos.xml	Catálogo de serviços e preço base	6 serviços
clientes.sqlite	Tabela clientes e contactos	30 clientes

Pressupostos de Negócio

Cada linha representa uma marcação de um serviço. Um cliente pode ter várias marcações e uma marcação pode ter vários pagamentos. As marcações analisadas são tratadas como serviços devidos..

Assume-se que o ficheiro de pagamentos está completo para o cenário. Por isso, a ausência de correspondência é tratada como zero pago. Os preços em falta nas marcações não são preenchidos com zero nem substituídos automaticamente pelo preço base do catálogo.

3 Estratégia utilizada

O workflow TP1_Estudio_ETL organiza o processamento por dependências entre nós. Na extração, cada fonte é lida no formato original. Na transformação, os dados são convertidos em tabelas, limpos e relacionados através dos identificadores. No carregamento, três CSV guardam o detalhe integrado, os totais mensais e as marcações para revisão.

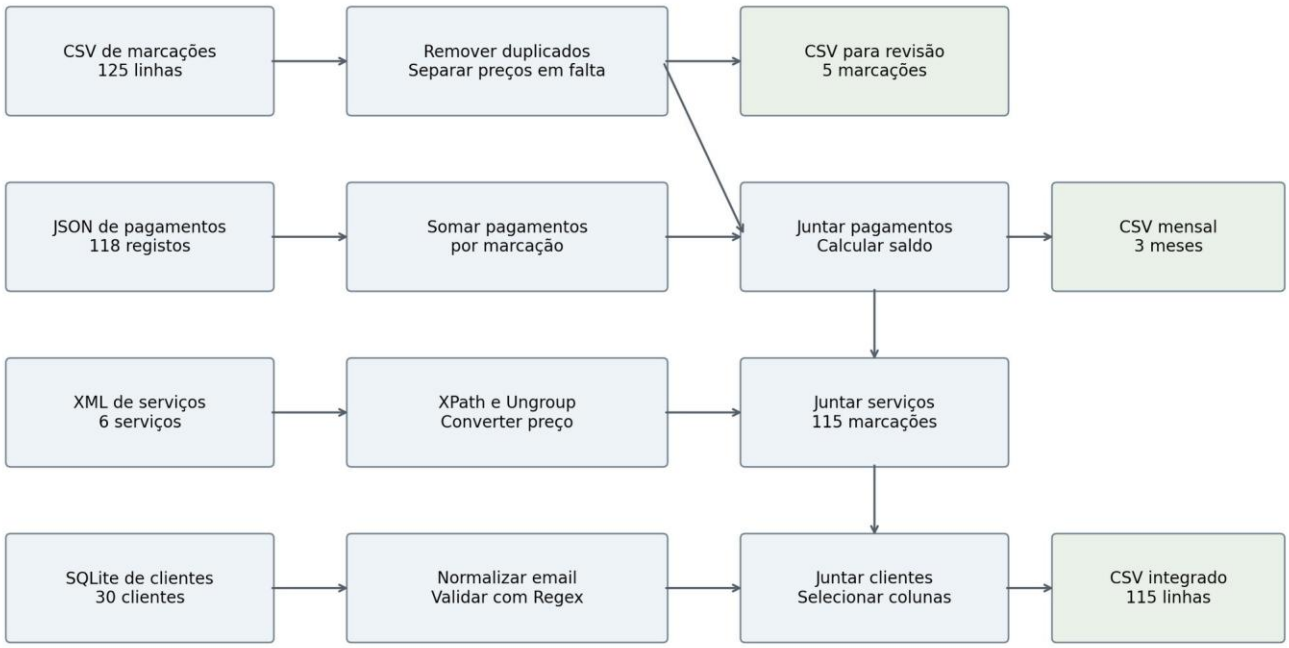


Figura 1 — Diagrama conceptual das dependências e saídas do workflow. Os blocos resumem grupos de nós.

Correspondências entre fontes

A chave id_marcacao relaciona as marcações com os pagamentos previamente somados. A chave id_servico acrescenta nome, categoria e preço base. A chave id_cliente acrescenta cidade e estado de validação do email. Os três Joiner preservam as marcações da entrada esquerda, mesmo quando não há correspondência na outra fonte.

Somar os pagamentos antes da primeira junção evita repetir uma marcação por cada pagamento e, consequentemente, somar várias vezes o preço do serviço. O resumo mensal é calculado depois de associar pagamentos, antes das junções com serviços e clientes, pois não depende dos atributos dessas duas fontes.

4 Transformações

Marcações e pagamentos

O CSV Reader lê marcacoes.csv em UTF-8, com ponto e vírgula como separador. O Duplicate Row Filter compara as cinco colunas da origem e elimina 5 linhas exatamente repetidas, ficando 120 marcações. O Row Splitter testa se valor está em falta: a saída superior envia 5 linhas para revisão (as que tem um símbolo de ?) e a inferior mantém 115 para análise.

O String to Date&Time converte data com o padrão yyyy-MM-dd. O Date&Time Part Extractor cria ano e mes. O JSON Reader e o JSON to Table transformam os 118 pagamentos em linhas e colunas. O GroupBy agrupa por id_marcacao e soma valor_pago, produzindo 88 grupos.

O primeiro Joiner associa essa soma às 115 marcações. O Missing Value substitui apenas a soma do pagamento em falta por zero. Existem 27 marcações sem pagamento associado. Utilizei o nó Math Formula para calcular e acrescentar o valor_em_falta através da expressão:

$valor$ - $Sum(valor_pago)$

Serviços e clientes

O XML Reader lê o catálogo. O XPath extrai id_servico, nome_servico, categoria e preco_base como coleções, usando os caminhos /servicos/servico/nome_do_campo. O Ungroup expande as quatro coleções em conjunto para obter uma linha por serviço. O String to Number converte preco_base para um tipo numérico. O segundo Joiner acrescenta estes dados por id_servico.

O SQLite Connector abre clientes.sqlite. O DB Query Reader executa SELECT id_cliente, nome, email, cidade FROM clientes. O String Manipulation cria email_limpo com lowerCase(strip($email$)), removendo espaços nas extremidades e convertendo o texto para minúsculas.

O Rule Engine classifica o email como Em falta, Formato valido ou Rever. A expressão regular utilizada é:

^[a-z0-9._%+-]+@[a-z0-9.-]+[.][a-z]{2,}$

O terceiro Joiner relaciona os clientes por id_cliente. Na saída integrada, 8 marcações têm estado Rever, correspondendo a 2 clientes distintos; as outras 107 têm Formato valido.

Seleção de colunas

O Column Filter remove nome, email e email_limpo da saída final. O Column Renamer altera valor para valor_servico e Sum(valor_pago) para total_pago. A saída conserva 14 colunas.

4 Transformações e resultados

Agregação mensal e carregamento

O GroupBy mensal agrupa por ano e mês da data da marcação, conta id_marcacao e soma o valor do serviço, o total pago e o saldo em falta. O Column Renamer atribui nomes legíveis às colunas. O total recebido de cada mês corresponde a pagamentos associados às marcações desse mês; não é uma análise independente por data de pagamento.

Mês de 2026	Marcações	Serviços €	Pago €	Em falta €
Agosto	35	1 000,00	820,00	180,00
Setembro	38	1 045,00	765,00	280,00
Outubro	42	2 030,00	1 297,50	732,50
Total	115	4 075,00	2 882,50	1 192,50

Os três CSV Writer utilizam ponto e vírgula, UTF-8, cabeçalhos e escrita sem RowIDs. A opção Overwrite substitui a exportação anterior, evitando acumular cópias em execuções repetidas.

Ficheiro de saída	Linhas	Colunas
marcacoes_integradas.csv	115	14
resumo_mensal.csv	3	6
marcacoes_para_revisao.csv	5	5

Verificação dos resultados

A inspeção dos ficheiros exportados confirmou 115 identificadores de marcação distintos na tabela integrada, sem campos vazios. Em cada linha verifica-se valor_servico = total_pago + valor_em_falta. Os totais do detalhe coincidem com os do resumo mensal. As 5 marcações para revisão são M004, M030, M060, M090 e M120 e mantêm o valor vazio.

A contagem de controlo é 125 linhas iniciais menos 5 cópias exatas = 120 marcações; 120 menos 5 sem preço = 115 marcações analisadas. O ficheiro KNWF exportado contém os dados de entrada e as saídas. Foi inspecionado o estado EXECUTED dos 28 nós.

Portabilidade
As origens e os destinos usam a área de dados do workflow, em vez de caminhos específicos do Windows. Por exemplo, knime://knime.workflow/data/input/marcacoes.csv aponta para um ficheiro incluído no projeto. Os resultados são escritos em data/output. Esta organização acompanha as recomendações de partilha e gestão de ficheiros do KNIME [2, 3].

5 Jobs e execução do processo

O projeto utiliza um único workflow KNIME. A orquestração é definida pelas ligações de dados apresentadas na Figura 1: um nó só pode executar quando as entradas de que depende estiverem disponíveis.

Para testarem a minha solução, devem importar o ficheiro, dataintegration/16077_TP1_Estudio_ETL.knwf para o espaço local do KNIME. Se forem pedidas extensões em falta, instalam-se as correspondentes aos nós JSON, XML e base de dados usados no projeto. Depois abre-se o workflow e executam-se os três CSV Writer, permitindo a execução dos respetivos antecessores. Para testar o processamento completo, repõe-se o workflow com Reset e volta-se a executar. Os ficheiros são consultados na área de dados do workflow importado, em data/output.

A pasta data/input incluída separadamente na entrega conserva cópias de consulta. As fontes efetivamente usadas pelo workflow são as cópias internas do KNWF. Os resultados externos em data/output são exemplos da execução exportada; não são automaticamente atualizados ao executar o workflow importado.

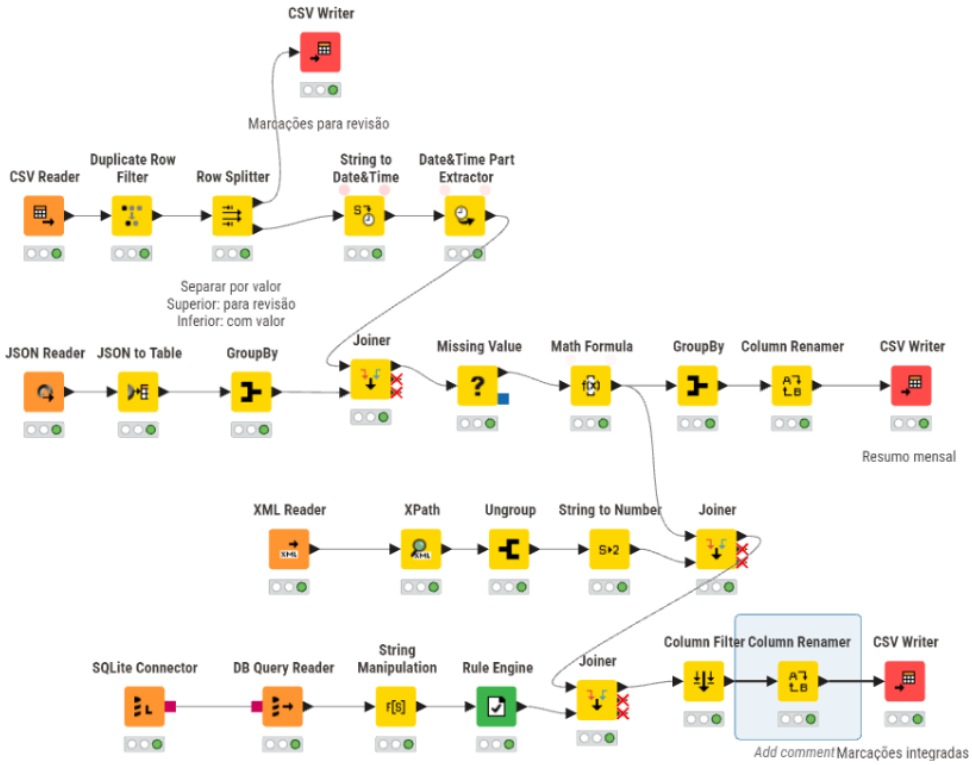
6 Vídeo com demonstração

Vídeo de demonstração: Abrir o vídeo
Repositório Git: ThifanyAntoni / tp01-16077_ISI
Aceder ao vídeo através do QR Code:

O vídeo apresenta o workflow, as principais operações de tratamento e os resultados. Vídeo com áudio a explicar um pouco do processo descrito acima. O mesmo link consta no README.md.

7 Conclusão e trabalhos futuros

O workflow demonstra a integração de fontes heterogéneas e o ciclo ETL completo. A remoção de duplicados e a separação de marcações incompletas tornam explícitos os registos considerados. A agregação de pagamentos antes da junção evita multiplicar o valor dos serviços. A solução produz 115 linhas integradas, um resumo de três meses e uma lista de cinco marcações para revisão.



Como evolução, pretendo incluir verificações de referências sem correspondência, valores negativos, pagamentos superiores ao preço, datas inválidas e cancelamentos. Também poderão ser acrescentados um resumo por data de pagamento, registo de auditoria, atualização de uma base de dados de destino e execução agendada.

8 Referências bibliográficas

[1] Ferreira, Luís e Ribeiro, Óscar. Integração de Sistemas de Informação — Trabalho Prático I, 2026/27. IPCA. Enunciado disponibilizado na unidade curricular.

[2] KNIME. Best Practices Guide. https://docs.knime.com/ap/latest/analytics_platform_best_practices_guide/ (consulta em 22/10/2026).

[3] KNIME. File Handling Guide. https://docs.knime.com/ap/5.8/analytics_platform_file_handling_guide/ (consulta em 22/10/2026).